

# Wissenschaftliches Arbeiten und Forschungsmethoden

Einheit 8: Auswertung von Studien - Teil 1: Datenvorbereitung,  
Stichprobenbeschreibung und Deskriptiv-Statistik

16.12.2024 | Prof. Dr. Caroline Zygar-Hoffmann

# Termine

| Einheit | Datum               | Hintergrundwissen & Theorieinput Thema                                                                  | Praxisteil Thema                                                                |
|---------|---------------------|---------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------|
| 1       | 15.10.24            | Präregistrierung im Forschungsprozess & Vorstellung Themenwahl                                          | Gruppenfindung, OpenNotebook in GoogleDoc, Themenauswahl                        |
| 2       | 22.10.24            | Literaturrecherche & Bewertung von Untersuchungsideen & Zusammenarbeit in Gruppen & Studienorganisation | Ordnerstruktur, Literaturrecherche, Entwicklung Forschungsfrage, formr Einstieg |
| 3       | 29.10.24            | Theoriearbeit & Studiendesign                                                                           | Hypothesen, Studiendesign, erste Analysegedanken, formr ctd                     |
| 4       | 06.11.24            | Operationalisierung & formr (Mittwoch & Raumwechsel!)                                                   | Operationalisierung & formr Implementierung & Testdurchlauf                     |
| 5       | 12.11.24            | Analyseplan (am Beispiel Interventionsthema)                                                            | Analyseplan                                                                     |
| 6       | 19.11.24            | Samplingplan & Durchführung von Studien                                                                 | Poweranalyse & OSF-Projekt & Präregistrierung finalisieren                      |
| 7       | 26.11.24            | Publikation von Studien mit Fokus auf Einleitung und Methode                                            | Daten sammeln                                                                   |
| -       | 03.12.24            | entfällt wegen Zeitraum Wiederholungsprüfung                                                            | Daten sammeln                                                                   |
| 8       | 10.12.24            | Publikation von Studien mit Fokus auf Einleitung und Methode                                            | Daten sammeln                                                                   |
| 9       | 17.12.24            | Auswertung von Studien - Teil 1: Datenvorbereitung & Deskriptivstatistik                                | Code-Review                                                                     |
| -       | 24.12.24 & 31.12.24 | entfallen wegen Weihnachtspause                                                                         | optional: an wissenschaftlichem Bericht arbeiten                                |
| 10      | 07.01.25            | Auswertung von Studien - Teil 2: Ergebnisse & Datenvisualisierung                                       | p-hacking App & Rückmeldung für Teilnehmer                                      |
| 11      | 14.01.25            | Publikation von Studien mit Fokus auf Ergebnisteil und Diskussion                                       | Feedback zwischen Gruppen                                                       |
| 12      | 21.01.25            | Publikation von Daten & das Wissenschaftssystem                                                         | Review innerhalb von Gruppen                                                    |
| 13      | 28.01.25            | Puffer                                                                                                  | -                                                                               |
| 14      | 04.02.25            | Freie Spitze und Fragen                                                                                 | -                                                                               |

# Laufende Studien

Hier die Links zu den aktuell schon angelaufenen Datenerhebungen Ihrer Kommiliton:innen. Ich ermuntere alle zur Teilnahme!

<https://surveys.osc.lmu.de/forever>

<https://surveys.osc.lmu.de/song> (nicht wundern: Erhebung von NachholerInnen aus dem letzten Semester; es dürfen auch die Personen vom Interventionsthema teilnehmen)

<https://surveys.osc.lmu.de/reflection> (Interventionsthema; d.h. Personen vom Interventionsthema dürfen nicht teilnehmen)

# Heutige Themen

## Datenvorbereitung

- Ordnerstruktur
- Datensätze kombinieren
- Bedingungsvariable als Dummy-Variable (0/1) einfügen
- Daten bereinigen und Variablen berechnen
- Code-Review

## Stichprobenbeschreibung und Deskriptivstatistik

## Praxisaufgabe



# Datenvorbereitung

## Ordnerstruktur

**Ziel einer guten Ordnerstruktur:** Sie können den Ordner mit allen Unterordnern kopieren, jemandem zukommen lassen, und diese Person versteht was gemacht wurde und wie die Analysen wiederholt werden können

**Englische Ordnernamen bevorzugt**, um breitere Verständlichkeit zu gewährleisten

Readme-Textdatei auf dem obersten Level empfohlen, um alles Nicht-Selbsterklärendes zu erklären

| Name                                                                                |                |
|-------------------------------------------------------------------------------------|----------------|
|  | analyses       |
|  | documentation  |
|  | literature     |
|  | manuscript     |
|  | preprocessing  |
|  | processed_data |
|  | raw_data       |
|  | results_plots  |
|  | README.txt     |

# Datenvorbereitung

## Ordnerstruktur

### Ordner "documentation"

- Hier können Sie Kontextinformationen zu Ihrer Studie ablegen, z.B. die formr-Exceldateien, die Präregistrierung, verwendete Fragebögen, das Open Notebook, Codebooks zu offenen Daten

### Ordner "literature"

- Hier können Sie die gesammelte Literatur zu Ihrem Thema abspeichern

Für beide Ordner ggf. weitere thematische Unterordner sinnvoll, je nach Menge der Dateien

### Ordner "manuscript"

- Hier können Sie die RMarkdown-Datei ablegen, in der Sie den Bericht schreiben (im Ordner Seminar auf studynet -> Vorlagen Prüfungsleistung -> RMarkdown Code -> "template.Rmd")

# Datenvorbereitung

## Ordnerstruktur

### Ordner "raw\_data"

- Hier sollen die originalen **Rohdaten** abgespeichert werden, so wie sie aus der Fragebogensoftware (bei uns: formr) rauskommen und ich sie Ihnen zuschicke
- Pro "Survey" in formr gibt es einen Datensatz/eine Datendatei
- **Sobald die Rohdaten hier einmal drinliegen, sollen sie nicht mehr verändert werden.**
- Es ist wichtig, die Rohdaten in ihrer Originalform vor jeglicher Bearbeitung zu behalten (z.B. um nicht versehentlichweise Daten zu überschreiben); zugespitzt gesagt: am besten Sie fassen (klicken) den Ordner danach nicht mehr an.
- Rohdaten sollten auch nicht mit Excel geöffnet werden, sondern direkt in R eingelesen werden -> Excel macht manchmal automatisch etwas, das die Daten zerstört (z.B. Zahlen in ein Datum umwandeln)
- Achtung: Rohdaten sollten nicht einfach irgendwo im Internet hochgeladen werden, sondern erst wenn Sie gemäß der Datenschutzrichtlinien bearbeitet worden sind (z.B. bei uns: Pseudonym gelöscht)

# Datenvorbereitung

## Ordnerstruktur

### Ordner "preprocessing" und "processed\_data"

- Im "preprocessing" Ordner liegen die R-Skripte drin, mit denen die Daten für die Analyse vorbereitet werden (siehe restliche Einheit)
- Verschiedene Vorverarbeitungsschritte können (müssen aber nicht) in verschiedene R-Skripte aufgeteilt werden, sollten dann aber nummeriert werden in der Reihenfolge in der sie ausgeführt werden müssen (z.B. "1-combine-data.R", "2-code-missings", "3-recode-variables")
- Die resultierende(n) vorverarbeitete(n) Datendatei(en) können mit dem Befehl `save()` im Ordner "processed\_data" abgespeichert werden, z.B.

```
save(data, file = "../processed_data/final_data.RData")
```

# Datenvorbereitung

## Ordnerstruktur

### Ordner "analyses"

- Hier sollen die R-Skripte abgespeichert werden, in denen Sie jegliche Analysen machen (z.B. Deskriptive Statistik, Hypothesen, Explorative Analysen)
- Am Anfang der Analyseskripte in R (und auch im Rmarkdown selbst) können Sie die vorverarbeitete(n) Datendatei(en) mit dem Befehl `load()` einlesen, z.B.:

```
load(file = "../processed_data/final_data.RData")
```

- Idealerweise für jedes Analyse"thema" ein eigenes R-Skript mit sprechendem Namen (z.B. "Descriptives.R", "Hypothesis\_1.R", "Exploration\_GenderDifferences.R")
- Die Analyseskripte selbst können Sie später auch mit dem Befehl `source()` in Ihrem RMarkdown Skript einlesen, d.h. die Ergebnisse aus den Skripten liegen dann für die weitere Bearbeitung im RMarkdown vor, z.B.:

```
source(file = "../analyses/Descriptives.R")
```

# Datenvorbereitung

## Ordnerstruktur

### Advanced: Projekte in R Studio

- Sie können in R Studio einen Ordner mit all seinen Unterordnern einem Projekt zuordnen (z.B. den Ordner in dem Sie die oben beschriebene Ordnerstruktur angelegt haben), indem sie unter "File -> New Project -> Existing Directory" den gewünschten Ordner auswählen
- Vorteil: Sie müssen das "working directory" nicht immer neu setzen, da es fix der Projektordner ist
  - In den bisherigen Befehlen wo bei `file = ".."` zwei Punkte und ein Slash `../` vorangestellt waren (um auf die obere Ordner Ebene zu wechseln) wären dann überflüssig, weil das working directory des Projekts der gewählte Projektordner ist
  - Im RMarkdown sollten Sie dann auch bei dem Pfeil neben "Knit" (die Wolle) unter "Knit Directory" -> "Project Directory" angeben, damit alle Pfade passen
- Weiterer Vorteil: Es werden beim Öffnen des Projekts alle zuletzt offenen R-Dateien aus dem Projekt geöffnet
- Wenn Sie für die Datenvorbereitung/-analyse zusammenarbeiten, dann benutzen idealerweise entweder alle aus der Kleingruppe die Projekt-Funktion oder gar keiner, weil sonst bei manchen die Pfade funktionieren und bei manchen nicht.

→ Probieren Sie es mal! Es tut nicht weh und hat Vorteile. Das Projekt im Nachhinein nicht zu benutzen geht immer (aber das ist eine Entscheidung, die Sie aktiv treffen müssen, da Sie dann die Pfade dann wieder entsprechend anpassen müssen).

# Datenvorbereitung

## Datensätze kombinieren: Schritt 1 - Daten einlesen

- Für den Fall, dass Ihre Studie nicht nur aus einem Survey in formr besteht, ist der erste Vorverarbeitungsschritt, dass Sie Ihre Datensätze in einen einzelnen Datensatz kombinieren
- Dafür müssen Sie zunächst alle Datensätze einlesen:

```
survey1 <- read.csv("../raw_data/survey1.csv")  
survey2 <- read.csv("../raw_data/survey2.csv")
```

usw.

# Datenvorbereitung

## Datensätze kombinieren: Schritt 2a - Leere sessions löschen

- In jedem formr Survey gibt es die Spalte "session" die eindeutig eine Zeile im Datensatz einer Durchführung des Fragebogen-Runs zuordnet (d.h. einer bestimmten Versuchsperson)
- Da jede Zeile am Ende eindeutig eine Person sein soll, können wir mit dieser Spalte also die Datensätze richtig zusammenfügen
- Zunächst müssen wir dafür aber alle Zeilen entfernen, in denen in "session" nichts drin steht (das ist i.d.R. der Fall, wenn der Fragebogensurvey nur geladen wurde, aber sonst nichts auf der Seite gemacht wurde):

```
survey1 <- survey1[survey1$session != "",]  
survey2 <- survey2[survey2$session != "",]
```

usw.

(R-Zeile 1 in Worten: Überschreibe das Objekt "survey1" mit den Zeilen vom Objekt "survey1" in denen in der Spalte "session" *nicht* "" (= nichts) drinsteht, und behalte alle Spalten)



# Datenvorbereitung

## Datensätze kombinieren: Schritt 2b - Leere sessions löschen

- Auch können wir Zeilen löschen, bei denen in "modified" nichts drin steht. Das sind nicht bearbeitete Fragebögen:

```
survey1 <- survey1[survey1$modified != "",]  
survey2 <- survey2[survey2$modified != "",]
```

- Wenn Sie präregistriert haben nur vollständige Daten zu nutzen, können Sie nach demselben Prinzip auch Daten ausschließen die keinen Eintrag in der "ended"-Spalte haben:

```
survey1 <- survey1[survey1$ended != "",]  
survey2 <- survey2[survey2$ended != "",]
```

# Datenvorbereitung

## Datensätze kombinieren: Schritt 3 - Zusammenfügen - Variante: Datensätze verschiedener Personen

- Die nun beschriebene Variante zum Zusammenfügen von Datensätzen ist für Sie relevant, wenn Ihre Studie so aufgebaut ist, dass die Personen entweder survey1 oder survey2 bearbeitet haben
- Das ist z.B. beim Interventionsthema einmal für die 3 verschiedenen Bedingungen der ersten Teils nötig, und einmal für die 3 verschiedenen Bedingungen der zweiten Teils (denn eine Versuchsperson hat jeweils nur eine der drei Bedingungen durchgeführt)
- Das ist auch bei den Gruppen mit eigenem Thema der Fall wenn Sie zwei Surveys hatten, und jede Person am Anfang randomisiert zu einem der beiden Surveys zugewiesen wurde
- Dann sollten Sie zunächst pro survey eine neue Variable anlegen, die die Bedingung kodiert:

```
survey1$condition <- "Gemeinsamkeiten"  
survey2$condition <- "Unterschiede"
```

## Datensätze kombinieren: Schritt 3 - Zusammenfügen - Variante: Datensätze verschiedener Personen

- Außerdem müssen Sie sicherstellen, dass beide Datensätze die gleichen Spalten haben. Dafür müssen Sie ggf. in dem Datensatz in dem eine Spalte fehlt, diese noch anlegen.
- Welche Spalten in survey2 fehlen, welche es in survey1 aber gibt, können Sie über folgenden Befehl herausfinden:

```
colnames(survey1)[!colnames(survey1) %in% colnames(survey2)]
```

- z.B. existiert die Variable "known" im Interventionsthema nur in den Bedingungen "Gemeinsamkeiten" und "Unterschiede", aber nicht in "Selbst". So fügen wir diese Variable (ohne Einträge, also mit **NA**s) zum dritten survey hinzu:

```
survey3$known <- NA
```

- Nun können Sie die Datensätze mit dem Befehl **rbind()** (das steht für "row bind") untereinander zusammenfügen:

```
survey <- rbind(survey1, survey2)
```

## Datensätze kombinieren: Schritt 3 - Zusammenfügen - Variante: Datensätze einer Person

- Die nun beschriebene Variante zum Zusammenfügen von Datensätzen ist für Sie relevant, wenn Ihre Studie so aufgebaut ist, dass die gleiche Person mehrere Surveys bearbeitet hat
- Das ist auch beim Interventionsthema der Fall, da Personen erst eine Bedingung des ersten Teils der Studie gemacht haben und dann eine Bedingung des zweiten Teils der Studie; diese beiden Teile möchten wir zusammenführen

## Datensätze kombinieren: Schritt 3 - Zusammenfügen - Variante: Datensätze einer Person

- Für das Zusammenfügen der Daten einer Person nutzen wir den Befehl `merge()`. Der Befehl muss wissen, welche Spalte er heranziehen soll, um die verschiedenen Datensätze richtig in einen einzelnen Datensatz zusammenzufügen, das ist in unserem Fall die Spalte "session"
- Für weitere Spalten, die es in jedem Survey gibt (z.B. `created` = der Zeitpunkt zu dem das Survey begonnen wurde, oder `ended` = der Zeitpunkt zu dem das Survey abgeschickt wurde), kann man "suffixes" festlegen, das sind Zeichen, die an die Spaltennamen drangehängt werden, um sie eindeutig einem Survey zuzuordnen
- Für die Suffixes bietet sich der Name der surveys an, wobei der erste survey-Name erst im letzten merge angegeben werden sollte, damit alle Spalten am Ende eindeutig benannt sind:

```
data <- merge(surveyA, surveyB, by = "session", suffixes = c("", "_surveyB"), all = TRUE)
data <- merge(data, surveyC, by = "session", suffixes = c("_surveyA", "_surveyC"), all = TRUE)
# Geschafft! Alle surveys befinden sich jetzt im Objekt `data`
```

- das Argument `all = TRUE` legt fest, dass alle Zeilen behalten werden sollen, auch wenn es in zwei Surveys keine zusammenpassenden session-IDs gibt. Das ist vor allem für die Studien relevant, in denen es unterschiedliche Bedingungen gab, aber ist auch sonst relevant (z.B. weil der Fragebogen abgebrochen wurde)

# Datenvorbereitung

## Bedingungsvariable als Dummy-Variable (0/1) einfügen

- Anhand der `condition`-Variable die wir vorher schon angelegt haben, können wir nun ganz einfach eine 0/1-Dummy-Variable daraus machen
- Wir legen dafür eine leere Variable an, und überschreiben die leeren Werte dieser Variable dann mit einer `ifelse()`-Funktion, welche 3 Argumente braucht:
  - erstes Argument der Funktion ist eine Bedingung ("if" also "wenn"), zu der ein Befehl ausgeführt werden soll. In unserem Fall wollen wir einen Wert einfügen, wenn in der "condition\_A" Spalte eine bestimmte Bedingung drinsteht
  - zweites Argument der Funktion ist der Befehl, der ausgeführt werden soll, wenn die "if"-Bedingung erfüllt ist. In unserem Fall wollen wir eine bestimmte Zahl vergeben, wenn jemand in der entsprechenden Bedingung war, z.B. `1`
  - drittes Argument der Funktion ist der Befehl, der ausgeführt werden soll, wenn die "if"-Bedingung *nicht* erfüllt ist ("else" also "sonst"). In unserem Fall wollen wir den Wert behalten, der bereits drin stand.

# Datenvorbereitung

## Bedingungsvariable als Dummy-Variable (0/1) einfügen

- Wenn Sie zum Beispiel in Ihrer H1 "Gemeinsamkeiten" mit "Unterschiede" vergleichen, könnte der Befehl lauten:

```
data$condition_H1 <- NA  
data$condition_H1 <- ifelse(data$condition_A == "Gemeinsamkeiten", 1, data$condition_H1)  
data$condition_H1 <- ifelse(data$condition_A == "Unterschiede", 0, data$condition_H1)
```

- Der erste ifelse()-Befehl in Worten: "Wenn in einer Zeile des Datensatzes in der `condition_A`-Spalte "Gemeinsamkeiten" drinsteht, dann schreibe bitte in die Variable `condition_H1` den Wert 1 rein, und sonst behalte den Wert der vorher drin stand."

## Bedingungsvariable als Dummy-Variable (0/1) einfügen

| session                                                | condition_A     | condition_H1 |
|--------------------------------------------------------|-----------------|--------------|
| -KJ9Tx5Wqiy9Zo_KuJfLldnHkevuPS3Up-l_Zsc6upZ-Ov2896m... | Gemeinsamkeiten | 1            |
| -KUf0nz4XyjLovLI2RMRveEKsMVNOHVkpAsUfry-P-Bs5-kaCJ...  | Selbst          | NA           |
| _06_DJwYow4af8WW8qrlWR1B7yjJ4Ge9iq5TDhKrQY5PKCCv...    | Selbst          | NA           |
| _kplxPlyoDZ4DMCF0JM0S8oryCIV9u0tQmZZouzIkyosRVeKT...   | Unterschiede    | 0            |
| 0BA2V_GVHDNVvRRShlbyL9XeC5xy_Dw5KSnkGLCwKEiqT52...     | Selbst          | NA           |
| 0BqSlSbEbTWOiFYk41BAqjjglbTfx0nvKmeVXMJzJc5ykyaBYTL... | Unterschiede    | 0            |
| 0COekPuGbqwnKih_WSOzfzqhiRgQrbpYitrmiCuvmlapzO64B...   | Selbst          | NA           |
| 0QafWxyzae1t0_0hKP4NWcQENfyrHLKBZ6liMD4Z03KE5yIXI...   | Gemeinsamkeiten | 1            |



# Datenvorbereitung

## Daten bereinigen: Eingabefehler korrigieren

Vor Beginn der Hypothesenprüfung:

1) versuchen, Eingabefehler zu identifizieren (nur relevant, falls Eingabe technisch gesehen fehlerhaft sein kann, z.B. bei offenen Antworten oder Eingabe von Paper-Pencil-Fragebögen in eine Datendatei)

2) Datensatz um Fehler bereinigen

Eingabefehler:

- oft Werte, die außerhalb des zulässigen Wertebereichs einer Variablen liegen
- hat eine Variable nur wenige Stufen (z.B. Geschlecht: 0, 1), lässt man sich mit einem geeigneten Befehl ausgeben, wie oft die Werte der betrachteten Variablen vorkommen
- Bei Variablen ohne exakt festgelegten Wertebereich (z.B. Alter) ist auf Extremwerte zu achten; so sind Altersangaben größer als 100 z. B. sehr unwahrscheinlich und sollten überprüft werden.
- Extremwerte springen auch bei graphischen Darstellungen ins Auge (Histogramm, Boxplot)

# Datenvorbereitung

## Daten bereinigen: Eingabefehler korrigieren

Beispiel: Eingabefehler

- Häufigkeiten Anzeigen lassen (z.B. Geschlecht: 0, 1) mit dem Befehl `table()`, z.B.:

```
table(data$Geschlecht)
```

- Erhielte man nun die Angabe, dass der Wert »0« (für männlich) 456-mal vorkommt, der Wert »1« 435-mal und der Wert »9« 3-mal, hat man damit bereits 3 Eingabefehler identifiziert.
- Nun lässt man sich die Nummern all derjenigen Fälle ausgeben, bei denen »Geschlecht=9« auftaucht mit dem Befehl `which()`, z.B.:

```
data[which(data$Geschlecht == 9),]
```

- Bei diesen Personen muss man in den Originalfragebögen nachschauen, welches Geschlecht sie angegeben haben und die entsprechenden Angaben in der Datendatei ändern.

# Datenvorbereitung

## Daten bereinigen: Missing-Data (unvollständige Datensätze)

Probleme:

- kleineres N → weniger Power
- größere Standardfehler (d.h. ungenauere Schätzungen)
- Verzerrungen, wenn fehlende Werte mit anderen Merkmalen zusammenhängen
- manche Tests lassen sich nicht rechnen

→ Je nach statistischem Test muss ggf. ein Datensatz ohne fehlende Werte (auf den Variablen, die in das Modell eingehen) erstellt werden

```
data_all <- data  
data_H1 <- data[!is.na(data$skala1),]
```

(R-Zeile 2 in Worten: Erstelle das Objekt "data\_H1" und speichere darin vom Objekt "data" alle Zeilen die in der Spalte "skala1" *nicht* leer (= `!is.na()`) sind, und behalte alle Spalten)

# Datenvorbereitung

## Daten bereinigen: ggf. nur für eigene Studie relevante Bedingungen auswählen

- Die Gruppen mit dem Interventionsthema vergleichen i.d.R. nur 2 Bedingungen (zumindest konfirmatorisch), d.h. es macht Sinn den Datensatz auf die Bedingungen zu kürzen, die für die eigene Forschungsfrage relevant sind
- Hinweis: Auch als Stichprobe sollten primär die Personen beschrieben werden, die an den Bedingungen teilgenommen haben, die für die eigene Forschungsfrage relevant sind

```
data <- data[!is.na(data$condition_A) & data$condition_A == "Gemeinsamkeiten" |  
            !is.na(data$condition_A) & data$condition_A == "Unterschiede",]
```

Der Befehl in Worten: Überschreibe das Objekt "data" mit den Zeilen vom Objekt "data" in denen die Spalte "condition" nicht leer ist und wo entweder "Gemeinsamkeiten" oder "Unterschiede" drinsteht, und behalte alle Spalten)

# Datenvorbereitung

## Daten bereinigen: Ausschlusskriterien

- Beispiel: Manipulationscheck nicht erfüllt

```
data <- data[data$mc == "Ja, ich habe die Instruktionen befolgt",]
```

(In Worten: Überschreibe das Objekt "data" mit den Zeilen vom Objekt "data" in denen in der Spalte "mc" "Ja, ich habe die Instruktionen befolgt" drinsteht, und behalte alle Spalten)

- In manchen Fällen macht es Sinn die Daten nicht direkt zu überschreiben, sondern zwei (in manchen Fällen auch mehr als zwei) Datensatz-Varianten zu erstellen, z.B. einen Datensatz *mit* den Personen, die den Manipulationscheck nicht erfüllt haben und einen *ohne* diese Personen (diese Datensätze dann sprechend benennen, z.B. `data_all` und `data_mc_passed`)

```
data_all <- data  
data_mc_passed <- data[data$mc == "Ja, ich habe die Instruktionen befolgt",]
```

# Datenvorbereitung

## Variablen berechnen: Variablen umkodieren und Skalen berechnen

- siehe Einheit zur Operationalisierung
- ggf. einzelne Items in die richtige Richtung umpolen, Beispiel-Code bei einer 7-stufigen Skala:

```
data$skala1_item1_r <- (data$skala1_item1-8)*-1
```

- Skalenwerte für Subskalen und Gesamtwerte bilden
  - Prüfen, ob Summenwert mit `rowSums()`, Mittelwert mit `rowMeans()` oder was anderes nötig ist
  - Dabei unbedingt darauf achten, dass bei Personen, bei denen es fehlende Werte für eine Skala gibt gemäß der Präregistrierung vorgegangen wird (z.B. die Skala dann nicht gebildet wird z.B. indem `na.rm = FALSE` als Argument übergeben wird)

```
data$skala1 <- rowSums(data[,c("skala1_item1_r", "skala1_item2", "skala1_item3")], na.rm = FALSE)  
data$skala2 <- rowMeans(data[,c("skala2_item1", "skala2_item2", "skala2_item3")], na.rm = FALSE)
```

# Datenvorbereitung

## Variablen berechnen: Variablen umkodieren und Skalen berechnen

- Überprüfung, ob alles geklappt hat (z.B. hinsichtlich Wertebereichen), z.B. mit dem Befehl `describe()` aus dem `psych` package

```
library(psych)
describe(data$item1)
describe(data$item1_r)
describe(data$skala1)
```

- Der Befehl bietet sich auch bei nicht selbst-erstellten Variablen zur Überprüfung an, ob alles normal aussieht

# Datenvorbereitung

## Variablen berechnen: z-Standardisierung

- Variablen ggf. zur besseren Interpretierbarkeit von Modellparametern z-standardisieren
- Konsequenz: Mittelwert der Variable auf 0 verschoben, Standardabweichung auf 1 verschoben ("normiert")
- Ist sinnvoll bei Variablen die keine natürliche 0 haben und/oder bei denen ein Abstand von 1 nicht natürlich ist (z.B. bei den meisten Likert Skalen)
- Beispiel:

```
data$skala1_z <- (data$skala1 - mean(data$skala1, na.rm = TRUE))/sd(data$skala1, na.rm = TRUE)
```



# Datenvorbereitung

## Variablen berechnen: Prä-Post-Differenz bilden

- Macht man einen Prä-Post-Vergleich, den man als AV vorhersagen möchte, muss man die entsprechende Differenz bilden:

Beispiel:

```
data$RS1_diff <- data$RS1_post - data$RS1_pre
```

- Interventionsgruppen: Achten Sie darauf, dass Sie die richtige Differenz bilden! Die erste Messung hat den Suffix \_pre, die zweite Messung den Suffix \_post und die dritte Messung den Suffix \_post1

# Datenvorbereitung

## Sonstiges

- ggf. sind noch weitere Schritte in der Datenvorbereitung nötig, z.B. Faktorvariablen als solche zu kodieren und ihnen sinnvolle Labels (= Gruppenbezeichnungen) zu vergeben
- Man sollte sich vor Beginn der Analysen einen Überblick darüber gemacht haben, dass möglichst alle Variablen so aussehen wie sie aussehen sollen → die Datenvorbereitung sollte abgeschlossen sein, bevor mit den Hypothesenprüfungen begonnen wird
  - Stellt sich erst im Nachhinein heraus, dass noch gravierende Kodierungs- oder Eingabefehler in den Daten stecken, müssen die Analysen wiederholt werden
  - Zudem bestünde die Gefahr, beim Bereinigen der Daten bewusst oder unbewusst im Sinne der eigenen Hypothesen vorzugehen
  - Dies betrifft auch die Frage, welche Fälle wegen fehlender oder fragwürdiger Angaben ggf. ganz aus den Analysen ausgeschlossen werden sollen

# Datenvorbereitung

## Abweichungen zur Präregistrierung

- Sie stellen bei der Datenvorbereitung fest, dass es total sinnvoll ist, bestimmte Angaben oder Personen auszuschließen, obwohl Sie das nicht präregistriert haben? Kein Problem! Erklären Sie, warum das so ist.
- Bei jeder Abweichung von der Präregistrierung kann man sich überlegen zu berichten, inwiefern sich die Ergebnisse dadurch ändern (z.B. von signifikant zu nicht signifikant, Vorzeichen ändert sich oder bleibt gleich)
- Beispiel aus einem Paper:

### Analytical Strategy

As preregistered, we winsorized outliers with scores outside  $M \pm 3 \times SD$  to the respective lower or upper bound. This procedure was used for 15 observations of PA and 58 observations of NA. We repeated analyses without outlier correction and found almost identical results. We used multilevel modeling (Hoffman, 2015)

# Datenvorbereitung

## Code-Review

- Macht es Sinn, dass nur einer aus Ihrer Gruppe die komplette Datenvorbereitung und Analyse macht? **Nein.**
  - Erstens, lernt dann nur einer wie Datenvorbereitung und Analysen funktionieren
  - Zweitens, machen wir alle Fehler (ich auch)
- **Idee vom Code-Review:** 4-Augen-Prinzip
  - Einer prüft den Code vom anderen
  - Voraussetzung: Code ist gut kommentiert und kann vom anderen nachvollzogen werden
  - mit Hashtags kann man in R Kommentare oder Überschriften schreiben, z.B.

```
# Summenwert für Skala1 bilden  
data$skala1 <- rowSums(data[,c("skala1_item1", "skala1_item2", "skala1_item3")], na.rm = FALSE)
```

# Datenvorbereitung

## Ergebnis-Abgleich

- **Ein Abgleich von Ergebnissen ist noch besser:** Jeder macht die Datenvorbereitung, und am Ende wird verglichen, ob alle zum gleichen Ergebnis kommen, d.h. hier zu den gleichen vorverarbeiteten Datensätzen und im nächsten Schritt zu gleichen Ergebnissen (der Weg muss nicht gleich sein - Hauptsache es kommt dasselbe raus)
  - Vergleich zweier Datensätze mit dem Befehl `all.equal()`
  - Zuvor müssen beide Datensätze mit `load()` eingelesen werden

```
load(file = "../processed_data/final_data_musterfrau.RData")  
load(file = "../processed_data/final_data_mustermann.RData")  
  
all.equal(final_data_musterfrau, final_data_mustermann)
```

→ R gibt Ihnen dann aus, an welchen Stellen sich Ihre Datensätze ggf. unterscheiden

# Stichprobenbeschreibung und Deskriptivstatistik

## Methodenteil: Stichprobenbeschreibung

- Hat man die Vorverarbeitung der Daten durchlaufen, erstellt man üblicherweise zunächst eine Stichprobenbeschreibung für den Methodenteil und eine Tabelle mit Deskriptivstatistik für den Ergebnisteil, bevor man zu den Hypothesentests übergeht
- Bei der Stichprobenbeschreibung berichtet man für die gängigen sozialstatistischen bzw. soziodemographischen Merkmale ...
  - Geschlecht
  - Alter
  - Familienstand
  - Bildungsgrad, Tätigkeit
  - Einkommen
  - Wohnort
  - ...
- Auswertung
  - **Numerische Merkmale:** empirische Range und M (SD) oder Med (IQR) mit den Befehlen `range()`, `mean()`, `sd()`, `median()`, `IQR()`
  - **Kategoriale Merkmale:** N (%) mit den Befehlen `table()` und `prop.table(table())`
  - In die Klammern der Befehle die relevante(n) Spalte(n) im Datensatz auswählen, z.B. `mean(data$variable1)`
- Gruppen mit eigenem Thema werden aufgrund der Anonymitätsanforderung nicht sehr viele soziodemographische Informationen erhoben haben. Dann bleibt es bei der Stichprobengröße (ggf. pro Gruppe) und eben den stichprobenbezogenen Variablen die Sie erhoben haben.

# Stichprobenbeschreibung und Deskriptivstatistik

## Methodenteil: Stichprobenbeschreibung

- Neben allgemeinen soziodemografischen Variablen werden im Rahmen der Stichprobenbeschreibung auch weitere für das Studienthema relevante Merkmale beschrieben
- Beispiel: Studie über Computerspiele
  - die Computererfahrungen der Probanden
  - durchschnittliche Spielzeit/Woche
  - ...

# Stichprobenbeschreibung und Deskriptivstatistik

## Ergebnisteil: Deskriptivstatistik

- Die deskriptiven Ergebnisse werden in einer Tabelle zusammengefasst
- Werden im Studiendesgin mehrere Gruppen untersucht sollte es eine Spalte pro Gruppe, sowie eine "Gesamt" Spalte geben
  - Ggf. kann dann auch für jede Variable ein t-test berechnet werden, um zu prüfen, ob es Gruppenunterschiede gibt (wären dann Störeinflüsse)
  - Debatte: Viele Signifikanztests haben hohe  $\alpha$ -Fehler Kumulierung (daher oft nur deskriptive Statistik)
- **In der Regel gilt es alle Fragebögen deskriptiv darzustellen (und im Methodenteil zu beschreiben), die Sie im Rahmen der Studie erhoben haben**, da Sie diese ja in irgendeiner Form für relevant für das Studienthema erachtet haben (Ausnahme sind große Studien, wo es ggf. den Rahmen sprengen würde alle Fragebögen zu berichten)
- Außerdem ist es üblich die Korrelationen zwischen allen erhobenen Variablen darzustellen (in einer zweiten Tabelle oder zusammen mit der ersten Tabelle); wenn eine Korrelation Teil einer Hypothese ist, wird sie meist trotzdem auch in der Gesamttabelle aufgeführt, aber im Fließtext separat angesprochen
- Manipulationschecks werden meist vor den Hypothesentests im Fließtext berichtet



# Stichprobenbeschreibung und Deskriptivstatistik

## Methodenteil oder Ergebnisteil: Reliabilität

- Angaben zur Reliabilität (  $\alpha$  oder  $\omega$  ) sind meist im Fließtext im Methodenteil bei der Beschreibung der Instrumente, manchmal findet man sie aber auch in der Tabelle der Deskriptivstatistik
- Berechnung der Reliabilität auf eigenen Daten z.B. mit `ci.reliability()` aus dem package **MBESS** (relevantes Ergebnis: "est" = "estimate" = Schätzwert der Reliabilität, am Besten zusammen mit Konfidenzintervall "ci.lower" und "ci.upper")

```
library(MBESS)
ci.reliability(data = data[, c("item1", "item2", "item3")], type = "omega")
```

# Stichprobenbeschreibung und Deskriptivstatistik

## Beispiel für eine Deskriptivstatistik-Tabelle

- Hier wurden Mittelwert, Standardabweichungen, Range, Reliabilität und Korrelationen gemeinsam dargestellt

Table 1. Descriptive statistics and correlations for trait measures

| Variables                        | <i>M (SD)</i> | Range    | $\omega_t$ | 1      | 2      | 3       | 4     | 5   |
|----------------------------------|---------------|----------|------------|--------|--------|---------|-------|-----|
| 1. Implicit pnCommunion          | 5.34 (2.12)   | 1 to 12  |            | .23    |        |         |       |     |
| 2. Explicit desire for closeness | 6.16 (0.69)   | 3.5 to 7 | .86        | .20*   | .10    |         |       |     |
| 3. Couple satisfaction index     | 66.30 (10.23) | 32 to 81 | .92        | .27*** | .61*** | .44***  |       |     |
| 4. Positive relationship quality | 6.11 (1.05)   | 1 to 7   | .92        | .17*   | .44*** | .47***  | .23   |     |
| 5. Negative relationship quality | 2.01 (1.27)   | 1 to 7   | .91        | -.12   | -.26** | -.45*** | -.17* | .18 |

*Note.*  $N = 152$  individuals from 77 couples. pnCommunion = partner-related need for Communion. The reliability coefficient  $\omega_t$  refers to McDonald's omega total, calculated with the *MBESS* package (Kelley, 2016). Cronbach's  $\alpha$  was equal to  $\omega_t$  for all measures, except for the explicit need for closeness,  $\alpha$  was .87 (calculated with the *psych* package, Revelle, 2016). Correlations below the diagonal refer to associations between individuals. Correlations on the diagonal refer to dyadic associations. *M (SD)* of pnCommunion refer to raw motive scores (number of motive categories). Correlations of pnCommunion were calculated with motive scores corrected for word count. \* $p < .05$ , \*\* $p < .01$ , \*\*\* $p < .001$ .

# Stichprobenbeschreibung und Deskriptivstatistik

## Bewertungsschema

Methodenteil:

|                         |   |                                                           |
|-------------------------|---|-----------------------------------------------------------|
| Beschreibung Stichprobe | 0 | keine/unzureichende Beschreibung der Stichprobe           |
|                         | 1 | Stichprobe ist mit allen relevanten Merkmalen beschrieben |

Ergebnisteil:

|                                                         |   |                                                                                                                 |
|---------------------------------------------------------|---|-----------------------------------------------------------------------------------------------------------------|
| Deskriptive Statistiken<br>(MW, SD, Korrelationen etc.) | 0 | Deskriptive Statistiken der Variablen, die in irgendeine Analyse eingegangen sind: fehlen überwiegend oder ganz |
|                                                         | 1 | Deskriptive Statistiken der Variablen, die in irgendeine Analyse eingegangen sind: fehlen teilweise             |
|                                                         | 2 | Deskriptive Statistiken der Variablen, die in irgendeine Analyse eingegangen sind: sind vorhanden               |

# Praxis

## Schritt 1: Ordnerstruktur nutzen

- Bereits vorhandene Dateien einsortieren

## Schritt 2: Preprocessing der Daten beginnen

- Wenn Sie mit der Datenerhebung schon begonnen haben, können Sie jetzt schonmal einen Auszug der Daten von mir anfordern, um mit dem Preprocessing beginnen zu können
- Den Zeitpunkt dafür, wann Sie den finalen vollständigen Datensatz bekommen möchten, können Sie selbst entscheiden
- Teilen Sie mir daher mit, ob Sie erstmal nur einen Auszug wollen, oder schon den finalen Datensatz (bei letzterem schließe ich die Umfrage danach)

## Schritt 3: Code-Review besprechen

- Wollen Sie ein 4-Augen-Prinzip, oder soll es jeder separat machen und dann vergleichen Sie die Ergebnisse?
- Bei 4-Augen-Prinzip: Wer macht welchen Teil, und wer reviewt welchen Teil?