

Wissenschaftliches Arbeiten und Forschungsmethoden

Einheit 11: Publikation wissenschaftlicher Daten

21.01.2025 | Dr. Caroline Zygar-Hoffmann

Heutige Themen

Hinweise

Gute wissenschaftliche Praxis

Open Data und Open Code

Übung: Wann sind die Daten anonymisiert / Wie einfach ist Deanonymisierung

Anonymisierungs-Möglichkeiten

Praxis

Hinweise

Bitte noch an Studien teilnehmen

- Folgende Studien brauche noch dringend Teilnehmer:

<https://surveys.osc.lmu.de/siblings>

<https://surveys.osc.lmu.de/bindungsforscher>

- Folgende Studien sind noch offen:

<https://surveys.osc.lmu.de/empowerment>

<https://surveys.osc.lmu.de/jagoda>

<https://surveys.osc.lmu.de/forever>

<https://surveys.osc.lmu.de/song>

Hinweise

Lehrevaluation ist gestartet!

Ich freue mich über Ihr Feedback, besonders in den offenen Antworten:

hsf.click/Eval-CFH

Gute wissenschaftliche Praxis

1) Arbeiten nach den "Regeln der Wissenschaft" ("lege artis")

- Anwendung üblicher wissenschaftlicher Methoden, gemäß dem "state of the art" (was Theorien, Methoden und Analysen angeht)
- Einhaltung der wissenschaftlichen Gütekriterien

2) (Selbst-)kritische Reflexion von Forschungsergebnissen

- keine Überinterpretation
- Verweis auf Limitationen
- Überprüfung durch peer-review Prozess, als Reviewer keine Gefälligkeitsreviews oder Reviews außerhalb des eigenen Kompetenzbereichs machen
- keine Interessenskonflikte oder transparenter Hinweis, wenn es welche gibt

3) Sicherung von Primärdaten für mindestens 10 Jahre unter Wahrung des Datenschutzes

4) Kennzeichnung der Beiträge von Kooperationspartnern, Konkurrenten, Vorgängern in der eigenen Arbeit

- angemessene Autorenschaftsregeln, keine Ehrenautorenschaften, kein Ghostwriting
- Korrekte Zitation, kein Plagiarismus

5) Keine Sabotage von Forschungsarbeiten

Wissenschaftliche Autorenschaft

- alle an der jeweiligen Studie sowie dem veröffentlichen Paper **maßgeblich** beteiligten Personen sollten ein Recht auf Autorenschaft haben → frühzeitige Absprachen treffen
- "Mitglieder des Forschungsteams, die nur kleine Teilarbeiten im Rahmen der Studie geleistet, aber nicht an der Publikation direkt mitgewirkt haben (z.B. studentische Hilfskräfte, die unter Anleitung die Datenerhebung, die Datenaufbereitung, und/oder die Datenauswertung), sind gemäß APA-Richtlinien keine Mitautoren (APA, 2009)" (Döring & Bortz, S. 136f) → **Acknowledgments**
- Abschlussarbeiten **können** bei entsprechender Qualität veröffentlicht werden → "Je nach Umfang der Betreuungsleistung einerseits und eigenständigen Arbeit der Studierenden andererseits sowie je nach Arbeitsanteil beim Schreiben des Manuskriptes kann das Spektrum reichen von studentischer Erstautorschaft, Mitautorschaft bis zu keiner Autorschaft (Fine & Kurdek, 1993)." (Döring & Bortz, S. 137)
- Besondere Rolle von Erstautor:in und Letztautor:in
 - Erstautor:innen sind i.d.R. für die Verfassung des Manuskript-Erstentwurfs verantwortlich
 - Erstautor:innen fungieren als Kontaktperson ("corresponding author") gegenüber der Zeitschrift und stellen die Einhaltung der Regeln guter wissenschaftlicher Praxis sicher
 - Letztautor:innen sind in der Psychologie i.d.R. in einer betreuenden bzw. supervidierenden Rolle

Gute wissenschaftliche Praxis

Wissenschaftliche Autorenschaft

CReditT: Taxonomie mit 14 Rollen, die ein:e Autor:in im wissenschaftlichen Publikationsprozess einnehmen kann

Conceptualization

Resources

Data curation

Software

Formal Analysis

Supervision

Funding acquisition

Validation

Investigation

Visualization

Methodology

Writing – original draft

Project administration

Writing – review &
editing

Gute wissenschaftliche Praxis

Ethische Prinzipien berücksichtigen

- Auswirkungen von Forschung auf Proband:innen und Gesellschaft?
- verantwortungsvoller Umgang mit Forschungsgeldern durch ressourcenschonende, zielführende Forschung (z.B. durch ausreichende Power, sequentielle Designs)
 - Sequentielle Designs erlauben während der Datenerhebung in die Daten reinzuschauen = "optional stopping", um zu prüfen ob bereits ausreichend Evidenz vorhanden ist um eine Hypothese zu evaluieren (indem z.B. verschiedene Alpha-Niveaus herangezogen werden → wenn es richtig gemacht wird, dann keine questionable research practice)

	80% power		
	Sequential N	Non-sequential N	Reduction (%)
$\delta=0.8$	39.17	52	24.67
$\delta=0.5$	100.82	128	21.23
$\delta=0.43$	135.73	172	21.09
$\delta=0.3$	278.38	352	20.91
$\delta=0.2$	625.09	788	20.67

Wieso offene Daten?

- Kernkriterien für Wissenschaft: Transparenz & Reproduzierbarkeit (Lupia & Elman, 2014; Merton, 1942; Popper, 1959)
- "Quality Check"
- Nachnutzung: Mehr Erkenntnisse aus den Daten möglich!
- Daten als Grundlage für Meta Analysen , v.a. bei nicht publizierten Studien
- Deutsche Forschungsgemeinschaft (DFG): "Sofern die Daten in Projekten erarbeitet wurden, die aus öffentlich rechtlichen Mitteln finanziert wurden, stehen sie im Grundsatz der Öffentlichkeit frei zur Verfügung" → Wissenschaftler werden von der Gesellschaft finanziert!
- in gewissem Sinne auch: Backup der Daten

Open Data

"Badges" (= Abzeichen) als Hinweis darauf, dass ein Artikel Open Data bereitstellt

MAY 12, 2016, AT 2:06 PM

Even Psychologists Respond To Meaningless Rewards

All they needed to be more open with their data was the promise of a badge showing they did it.

By Christie Aschwanden

Filed under Scientific Method



The badges, as illustrated by the Center for Open Science.





Fig 2. Reportedly available data. Percentage of articles reporting open data by half year by journal. Darker line indicates *Psychological Science*, and dotted red line indicates when badges were introduced in *Psychological Science* and none of the comparison journals. Underlying data (<https://osf.io/a29bt/>) and scripts (<https://osf.io/bdtnq/>) to reproduce this figure can be found on the Open Science Framework.

doi:10.1371/journal.pbio.1002456.g002

Open Data

"Badges" (= Abzeichen) als Hinweis darauf, dass ein Artikel Open Data bereitstellt

Anzahl der vergebenen Badges im Journal *Psychological Science* 2014-2018:



FAIR Prinzipien (Wilkison et al., 2016)

Veröffentlichte Daten sollten folgende Kriterien erfüllen:

- **F**indable: Die Daten sollten für Menschen und Computer leicht zu finden sein (z.B. in entsprechenden Archiven).
- **A**ccessible: Die Daten müssen offen und frei zugänglich sein.
- **I**nteroperable: Die Daten müssen technisch nachnutzbar sein (z.B. ein nicht-proprietäres Dateiformat aufweisen).
- **R**eusable: Die Daten müssen so dokumentiert sein, dass sie sinnvoll genutzt werden können.

Datendokumentation

- Um offene Daten verständlich und dadurch gut nachnutzbar zu machen braucht es eine gute Datendokumentation → Codebook
- Im Codebook wird für jede Variable beschrieben ...
 - ... wie sie heißt (idealerweise werden dennoch Variablennamen so selbsterklärend wie möglich gewählt)
 - ... was für einen Variablentyp (kontinuierlich/diskret) sie hat
 - ... welche Instruktion sie hatte
 - ... welche Antwortmöglichkeiten es gab
 - ... wie diese Antwortmöglichkeiten kodiert wurden

Datendokumentation

Weiterführende Informationen sind immer sinnvoll, z.B. Quellenangabe zu den genutzten Fragebögen, oder falls relevant Erklärung zu fehlenden Werten/Werten die nicht Teil der Antwortoption sind:

Information	Description	Individual item	Scale score	Demographic	Technical
Name of the variable	The name of the variable, exactly as it is displayed in the dataset	BFI_extra_1	CFT-total	Gender	Time
Type of the variable	The type of the variable, usually numeric, factor, date, or character	Numeric	Numeric	Factor	Date
For questionnaire items					
Wording of the item	The original wording of the item, in its original language	„Ich gehe aus mir heraus, bin gesellig.“	–	„Bitte geben Sie Ihr Geschlecht an.“	–
English translation of the item	An English translation of the item (note, this does not need to be a validated one)	“I get out of myself, I’m sociable.”	–	“Please indicate your gender.”	–
Questionnaire/Source	The source of the item	BFI-2	CFT-20-R	Generated ad hoc	–
Dimension the item belongs to	If the item is part of a scale, the scale the item belongs to	Extraversion	–	–	–
Response format	The format on which the response was given.	5-point rating scale	–	Single choice	–
Response labels	The labels of the response scale. If this is too long, it can be added on an additional sheet in the codebook	response_list_bfi	–	response_list_gender	–
Theoretical minimum	Lowest theoretical value the variable could take	1	55	–	–
Theoretical maximum	Highest possible value the variable could take	5	160	–	–
Coding of item	If the item is coded in the direction of the construct or not	No	–	–	–
Optional item	Indicates if the item was optional or mandatory	Yes	–	No	–
Coding of missing data	Indicates how missing data are coded	–77	NA	–	NA
Description	A brief, verbal description of the variable, especially if not an item from a survey	–	Score of the dimension	–	The time the survey was taken by the participant
Concerning study design (Examples)					
Rating source	Indicates who responded to the survey	Self	–	Self	–
Assessment wave	In studies with multiple waves, when was the item taken	First assessment	Laboratory assessment	First assessment	–
Part of survey	In larger studies, indicate block or part of survey	Personality	Cognitive ability	Demographics	–
Additional information					
Link	If available, a link to an online source of the survey/ item/measure	https://search.gesis.org/instruments_tools/zis247	–	–	–
Reference	Source of the survey or assessment tool	Danner et al. (2016)	Weiß (2019)	–	–
Comment	An additional comment in plain text, if required	–	–	–	–

Note. Information = Information that is presented in the codebook; Description = a description of that information; Individual Item = an example for an individual item from a survey; Scale Score = an example for a scale score from a questionnaire or test; Demographic = example for a demographic item; Technical = example for an item that is not responded to by the participant.

Datendokumentation

Weiterführende Informationen sind immer sinnvoll, z.B. englische Originalformulierungen:

Response list	Coded response	Label	Translation
response_list_bfi	1	Stimme überhaupt nicht zu	Disagree strongly
	2	Stimme eher nicht zu	Disagree a little
	3	Teils, teils	Neutral
	4	Stimme eher zu	Agree a little
	5	Stimme voll und ganz zu	Agree strongly
response_list_gender	1	Männlich	Male
	2	Weiblich	Female
	3	Divers	Non-binary
	4	Keine Angabe	Prefer not to say

Note. response_list = the name of the list, which can then be referenced in each item that makes use of this scale; coded response = the numerical value in the data frame that corresponds to the “label”; translation = an English translation of the label.

Open Data

Grenzen von Open Data: Personenbezogene Daten

Was sind "personenbezogene Daten"?

- "Data that directly can identify a person : Name, address , email address , fingerprints , date of birth , genetic data"
- "But also unique combinations of other data that allow to identify a single person"
- "who can be identified, directly or indirectly, by means reasonably likely to be used by [...] any [...] natural or legal person" (aus der DSGVO)
- e.g., wer ist der männliche, 46-jährige Student im ersten Psychologie-Semester an der LMU?
- Wenn Teile der Daten nicht veröffentlicht werden können, heißt das nicht, dass der gesamte Datensatz nicht veröffentlicht werden kann → Legitime Datenschutzbedenken und Open Data schließen sich nicht aus!

Was sind "besonders sensible Daten"? → § 9 (1) DSGVO

- rassische und ethnische Herkunft
- politische Meinungen
- religiöse oder weltanschauliche Überzeugungen
- Gewerkschaftszugehörigkeit,
- genetische Daten
- biometrischen Daten zur eindeutigen Identifizierung einer natürlichen Person
- Gesundheitsdaten
- Daten zum Sexualleben oder der sexuellen Orientierung → Wenn nicht nötig, nicht erheben! Ansonsten besondere Maßnahmen notwendig.

Open Data

Grenzen von Open Data: Personenbezogene Daten

Do's and Don'ts (Meyer, 2018)

- DON'T promise to destroy your data
- DON'T promise not to share data
- DON'T promise that research analyses of the collected data will be limited to certain topics
- DO get consent to retain and share data
- DO incorporate data retention and sharing clauses into IRB templates
- DO be thoughtful when considering risks of re identification
- DO consider working with a data repository
- DO be thoughtful when selecting a data repository

Open Data

Grenzen von Open Data: Personenbezogene Daten

Anonymisierung


- "Anonymisieren ist das Verändern personenbezogener Daten derart, dass die Einzelangaben über persönliche oder sachliche Verhältnisse nicht mehr oder **nur mit einem unverhältnismäßig großen Aufwand an Zeit, Kosten und Arbeitskraft** einer bestimmten oder bestimmbaren natürlichen Person zugeordnet werden können." (Bundesdatenschutzgesetz)
- Was "unverhältnis großer Aufwand" ist, kann von mehreren Faktoren abhängen (wer versucht es? ist es in 10 Jahren einfacher als jetzt?)
- Während es also keine 100% Garantie zur Anonymität gibt, ist das auch nicht nötig, solange man in einer Risikoabschätzung zu dem Schluss kommt, dass es ausreichend unwahrscheinlich ist (unter der Berücksichtigung der Folgen, die eine Deanoymisierung hätte)

Grenzen von Open Data: Personenbezogene Daten

Risikoeinschätzung

- Wer könnte Interesse an einer Deanonymisierung haben? Wer hat zusätzliche Informationen und ein Motiv jemanden zu identifizieren?
- Vielleicht ist der CIA-Hacker mit dem Supercomputer nicht der wahrscheinlichste Angreifer und wir sollten uns viel mehr um die studentische Hilfskraft sorgen, welche vollen Zugriff auf die Daten hat und die Kommilitonen leicht identifizieren kann
- Besondere Vorsicht ist bei dyadischen Daten geboten: Romantische Partner haben zum Beispiel viele zusätzliche Informationen (z. B. Metadaten wie "Wann hat mein Partner die Fragebögen ausgefüllt?"), und wahrscheinlich ein gewisses Motiv
- Daten auf keinen Fall bei ChatGPT hochladen!

Open Data



Open Code = Reproduzierbarer Code

- Zusammen mit den Daten ist es sinnvoll, den R-Code und/oder das RMarkdown-Dokument zu veröffentlichen: Je nachdem was nötig ist um nachzuvollziehen welche Datenvorbereitung und Datenanalyse auf Code-Ebene durchgeführt wurde
- Jemand Anderes sollte den Code (von oben nach unten) auf den Daten durchführen können, ohne auf Errors zu stoßen → Reproduzierbarkeit!
- Auch hier ist wichtig für die Nachnutzbarkeit, dass der Code verständlich ist, was man vor allem durch Kommentare erreicht (z.B. # Skalenbildung, # Z-Standardisierung, # Voraussetzungsprüfung Analyse Hypothese 1, # Analyse Hypothese 1)
- Für Ihren Bericht soll der Code zusammen mit den anonymisierten (!) Daten auf dem OSF hochgeladen werden (in dasselbe Projekt wo auch die Präregistrierung hochgeladen wurde)
- Falls Sie die Analysen individuell gemacht haben, dann am Besten pro Gruppenmitglied einen neuen Unterordner mit dem eigenen Namen im Projekt anlegen und dort die eigenen Code-Dateien ablegen

Open Data und Open Code

Bewertungsschema

Zugang zu Präregistrierung, Open Data (mit Codebook) und reproduzierbaren Skripten	0	Zugang nicht vorhanden
	1	Zugängliche URL vorhanden, aber nicht alle Elemente vorliegend (z.B. kein Codebook) oder alle Elemente intern abgegeben, aber kein Hinweis darauf im Text
	2	Zugängliche (persistente) URL vorhanden, mit vollständigen Elementen; z.B. am Anfang des Methodenteils (Hinweis: OSF-Links sind persistent; private Webseiten/Uniseite normal nicht). Falls intern präregistriert, bzw. Daten deponiert wurden, wurde im Text ein entsprechender Hinweis gemacht, wo es zu finden ist (z.B. beim Dozenten).

Übung: Wann ist mein Datensatz anonymisiert / Wie einfach ist eine Deanonymisierung?

Bitte Umfrage ausfüllen: <https://surveys.osc.lmu.de/anonymity>

Bitte hier eintragen falls Umfrage ausgefüllt: https://docs.google.com/document/d/10A_6uA2F2FBjF-hG7AqEFhgj9ma0xt9yS_wc6hZmxE4/edit

Ihr Alter		Haben Sie neben Ihrem Studium einen Nebenjob?	ja nein
Ihr Geschlecht	☐ weiblich ☐ männlich ☐ anderes/keine Angabe	Wohnen Sie in München?	ja nein
Sind Sie verheiratet, oder leben Sie in einer Partnerschaft mit festem Freund bzw. fester Freundin, oder sind Sie zurzeit Single, also ohne feste Partnerschaft?		Haben Sie schonmal etwas anderes als Psychologie studiert?	ja nein
Ich strebe derzeit den Beruf des Psychotherapeuten an	ja nein	Nennen Sie eine peinliche Sache über sich, die Sie im Rahmen der Vorlesung preisgeben würden (kann, muss aber nicht wahrheitsgemäß sein).	
Ich besitze einen Instagram-Account.	ja nein		
Haben Sie mindestens ein Geschwister?	ja nein		

Anonymisierungs-Möglichkeiten

Einzigartige Kombinationen erkennen und verhindern

Erkennen:

```
library(dplyr)

# let's try age and gender (1 = male, 2 = female)
unique_combos <- data %>%
  group_by(alter, geschlecht) %>%
  summarise(n = n()) %>%
  arrange((n))

# how many unique combinations do we have with age and gender?
table(unique_combos$n)

# show some of the critical ones
unique_combos[unique_combos$n == 1,]
```

Anonymisierungs-Möglichkeiten

Einzige Kombiaktionen erkennen und verhindern

Verhindern:

- "binning", z.B. Alter --> Alterskategorien, mehrere seltene Antworten --> in einer Antwortkategorie "andere Antworten" kombinieren → Danach überprüfen, ob das ausreichend war, d.h. keine einzigartigen Kombinationen mehr vorhanden sind!
- "fuzzing", z.B. ± 0.5 Standardabweichungen Rauschen hinzufügen (v.a. bei kontinuierlichen Antworten relevant, für Variablen die in Analysen eingehen nicht besonders geeignet)
- "deleting", z.B. Freitextantworten, Datumsangaben, Uhrzeiten, Variablen die für die Analysen nicht relevant sind

→ **Diese Maßnahmen verändern und reduzieren den Wert eines Datensatzes. Unbedingt dokumentieren und eine gute Balance finden zwischen Anonymität und Nutzbarkeit der Daten!**

Anonymisierungs-Möglichkeiten

Einzigartige Kombinationen erkennen und verhindern

Verhindern:

```
# let's make age bins
data$Alterskategorie[data$alter < 20] <- "17-19 Jahre"
data$Alterskategorie[data$alter > 19 & data$alter < 25] <- "20-24 Jahre"
data$Alterskategorie[data$alter > 24 & data$alter < 30] <- "25-29 Jahre"
data$Alterskategorie[data$alter > 29] <- "30-53 Jahre"

table(data$Alterskategorie)

## check whether we did a good job, and repeat until there are no unique entries left

## Done? Good! Save anonymized data in a separate file to share
write.csv(data, file = "raw_anonym/data_anonymized.csv", row.names = FALSE)
```

Praxis

Schritt 0: An Lehrevaluation teilnehmen: hsf.click/Eval-CFH

Schritt 1: Überlegen und prüfen, ob es Variablen gibt, die einzigartige Kombinationen bilden könnten und damit die Anonymität Ihrer Teilnehmer gefährden

Schritt 2: Hinreichend anonymen Datensatz erstellen

- Rohdaten in R einlesen (d.h. nicht die Rohdaten selbst verändern! Diese lokal immer unangetastet behalten.)
- in R ggf. einzigartige Kombinationen durch binning oder deleting verhindern (wenn es hierbei Hilfe in R braucht, bitte melden)
- in R Pseudonym aus den Daten löschen (`data$pseudonym <- NA`)
- Neuen anonymen Datensatz abspeichern

Schritt 3: Daten mit Codebook veröffentlichen

- Anonymen Datensatz im OSF-Projekt hochladen (wo auch die Präregistrierung liegt)
- formr Exceldateien im OSF-Projekt hochladen (wo auch die Präregistrierung liegt)

Schritt 4: Code veröffentlichen

- Entweder als Gruppe, oder individuell (in nach Name benannten Unterordnern)